



מדריך שדה למהנדס המערכת

זיהוי וגילוי אובייקטים בוידאו

אימון, מדידה ופריסה של מודלי Object Detection — מושגים,
משוואות, מלכודות והשאלות הנכונות לצוות · מוקד: רחפנים, זמן אמת,
Edge

REV A · יולי 2026 · מסמך הנדסי פנימי · אוריינות, לא קוד

01 מהי בעיית הזיהוי — מנקודת מבט מערכתית

מתי	קלט ← פלט	בעיה
"יש/אין" — בלי איפה	תמונה ← תווית אחת	Classification
הצורך שלנו: מה, כמה, איפה	תמונה ← רשימת עצמים: מחלקה + תיבה	Object Detection
מדויק ויקר; לרוב מיותר ליעד אווירי	תמונה ← מסכה פיקסל-לפיקסל	Segmentation

ההבדל בין השורה הראשונה לשנייה משנה את כל שרשרת הדאטה, המדדים והכשלים: ברגע שיש "איפה" — מתייגים תיבות, מודדים חפיפה, ונלחמים בהתרעות שווא במיקום.

שלוש שאלות שמגדירות את המערכת לפני המודל

- **טווח וגודל:** באיזה טווח, ובכמה פיקסלים, חייבים לזהות?
- **זמן:** מה ה-latency המותר מהחיישן עד החלטה?
- **מחיר טעות:** מה יקר יותר — פספוס (FN) או התרעת שווא (FP)? זה קובע את נקודת העבודה.

למה רחפן הוא יעד קשה — הפיזיקה


$$p \approx \frac{D \cdot W_{px}}{R \cdot \theta_{HFOV}}$$

גודל העצם בפיקסלים: D — גודל העצם (מ'), W — רוחב הפריים (px), R — טווח (מ'), θ — שדה ראייה אופקי (רדיאנים)

הצבה לרחפן 0.35 מ' (מחלקת Mavic) במצלמת 1080p:

$$\underbrace{\frac{0.35 \times 1920}{500 \times 1.047}}_{60^\circ, 500m} = 1.3px \quad \underbrace{\frac{0.35 \times 1920}{2000 \times 1.047}}_{60^\circ, 2km} = 0.3px \quad \underbrace{\frac{0.35 \times 1920}{500 \times 0.087}}_{5^\circ, 500m} = 15.4px$$

עדשה רחבה: תת-פיקסל כבר ב-500 מ'. רק זום צר מביא את היעד מעל רצפת הזיהוי המעשית (10~15px)



איור 1 · גודל רחפן בפיקסלים כפונקציה של טווח ועדשה; האזור האדום — מתחת לסף הזיהוי

- **דומה לציפור:** אתגרי Drone-vs-Bird רצים מ-2017 והבעיה לא "פתורה"; ההפרדה האמינה מגיעה מהקשר זמני (רצף פריימים), לא מפריים בודד.

- **הפער מובנה:** אותו מודל בדיוק — AP 17.6 על עצמים קטנים מול 62.4 על גדולים (RT-DETR, COCO). פי 3.5. הגדרות COCO: קטן $> 32^2 \times p$, בינוני $32^2 - 96^2$, גדול $< 96^2$.

▲ מלכודת TRAP-06

"עוד epochs" לא מייצרים פיקסלים. אם היעד קטן מהסף אחרי ה-resize — זו בעיית חיישן/עדשה/טווח, לא בעיית אימון.

← שאל: "מה גודל העצם הקטן ביותר בפיקסלים, אחרי ה-resize של הרשת?"

02 דאטה ותיוג — הדאטה הוא המוצר


ANNOTATION GUIDELINES · מסמך שבלעדיו אין עקביות: גודל מינימלי לתיוג (10×10), דגלי הסתרה (מלא / חלקי $< 30\%$ / כבד $> 30\%$), עצם חתוך, תיבה צמודה. נשמר בפורמט COCO/YOLO — הקונספט חשוב, הפורמט לא.

רעש תיוג הורג עצמים קטנים — המתמטיקה

הזזה של תיבת 10×10 ב- 2×100 אלכסונית:

$$IoU = \frac{|A \cap B|}{|A \cup B|} = \frac{8 \times 8}{10^2 + 10^2 - 64} = \frac{64}{136} \approx 0.47 \quad \text{vs} \quad \frac{98 \times 98}{2 \cdot 100^2 - 9604} \approx 0.92$$

אותה טעות אנושית של 2×100 : קטלנית לתיבת 10×10 (מתחת לסף!), זניחה לתיבת 100×100



איור 2 · טעות תיוג זהה, השפעה הפוכה — לכן QA תיוג לעצמים קטנים חייב להיות קפדני פי כמה

חוסר איזון — הנדיר הוא המסוכן

התרחישים הנדירים בדאטה (רחפן קרוב, לילה, ערפל) הם הקריטיים מבצעית. בתוך הרשת החוסר-איזון קיצוני: מאות מיקומי רקע על כל עצם. גלאים דו-שלביים מקבעים יחס 1:3 חיובי:שלילי; חד-שלביים משתמשים ב-Focal Loss:

$$FL(p_t) = -\alpha (1 - p_t)^\gamma \log(p_t)$$


הגורם $\gamma^{(p-1)}$ מדכא את הגרדיאנט של דוגמאות קלות — הרשת מתרכזת בקשות

שתי המלכודות הגדולות

TRAP-01 · Frame Leakage — החמורה ביותר ▲

חלוקת train/test ברמת פריים שמה פריימים כמעט-זהים משני הצדדים ← mAP מנופח. מעבר לחלוקה ברמת סרטון הוריד mAP מדווח מ-0.91 ל-0.62 בתרחיש טיפוס. הדמו מושלם — עד השטח.

← שאל: "החלוקה ברמת סרטון או פריים? מי אימת שאין דליפה?"



איור 3 · Frame Leakage: פריימי test (כתום) בתוך סרטוני train — המודל "כבר ראה" את התשובות

מודל שאומן על דאטה אינטרנטי/RGB ייכשל על הסנסור, הטווח והתאורה שלך. נמדד: אימון RGB ← בחינה על $mAP = IR$ מלא 0.32 בלבד. מעבר תחום עולה 20–50 נקודות.

← שאל: "כמה אחוז מהדאטה צולם בסנסור ובתנאי היעד?"

כלכלת תיוג (2026): \$0.02–\$0.10 לתיבה פשוטה · CVAT (קוד פתוח) עם איטרפולציית keyframes חוסך עד ~90% בווידאו · דאטהסטים ציבוריים שמישים: Anti-UAV (410 רצפי RGB+IR), DUT Anti-UAV (10,000 תמונות) — ברובם הרחפן >5% משטח הפריים.

03 משפחות מודלים — ברמת בלוקים

One-Stage (YOLO, SSD, RetinaNet)	Two-Stage (Faster R-CNN)	עיקרון
ישר מהתמונה לתיבות	שלב 1 מציע אזורים ← שלב 2 מסווג ומדייק	
FPS 155–45	GPU על FPS 5~	מהירות
קרוב, ולעיתים עוקף בדורות החדשים	גבוהה-היסטורית	דיוק
זמן אמת / edge	עיבוד אופליין / שרת	מתאים ל-

כלל אצבע מהספרות: ≤ 20 FPS נחשב "זמן אמת". ההחלטה נגזרת מתקציב ה-latency על חומרת היעד — לא מהעדפת הצוות.

אנטומיה של גלאי




איור 4 · Backbone (חילוץ מאפיינים) ← Neck FPN+PAN (מיזוג סקאלות) ← Head (מחלקה+תיבה) — כל טענת דיוק עוברת כאן

- **Backbone** — קונבולוציות מוערמות. השכבות הראשונות לומדות בעצמן גלאי-קצוות — בדיוק ה-primitives הקלאסיים:

$$K_{blur} = \frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \quad K_{sharp} = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix} \quad G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad |\nabla I| = \sqrt{G_x^2 + G_y^2}$$

קרנלים 3×3 קלאסיים: טשטוש, חידוד, Sobel — הרשת לומדת את המספרים האלה בעצמה בשכבה הראשונה



איור 5 · אותה תמונת רחפן, ארבעה קרנלים — הצינור פיקסל-feature שממנו בנויה CNN

- **Neck (FPN+PAN)** — עמוק = חזק סמנטית וגם מרחבית; רדוד = הפוך. ה-FPN ממזג. כמעט חובה לעצמים קטנים; לזעירים מוסיפים P2 head (stride-4).
- **Head** — anchor-free בדור הנוכחי (YOLOv8+). כשיש anchors — גוזרים מהדאטה (k-means), לא ידנית.


- **NMS** — דילול תיבות כפולות; עולה זמן ומתנפח בסצנה עמוסה. דגמי 2026 (YOLO26, RT-DETR) מוותרים עליו — .end-to-end

מצב השוק 2026 · בקצרה

משפחה	רישיון	נתון מייצג (COCO, T4)
Ultralytics YOLO11/26	AGPL — שימו לב משפטית	n: mAP 39.5 @ 1.5ms · x: 54.7 @ 11.3ms
RT-DETR (Baidu)	Apache-2.0	NMS ~50–57, AP ללא
RF-DETR (Roboflow)	Apache-2.0 (עד Large)	Nano: 48.4 @ 2.3ms

החלטה מערכתית מפורשת: מודל כבד בשרת (אימות/אופליין) מול קל על הפלטפורמה (התרעה בזמן אמת) — לרוב שניהם, אבל שמישהו יחליט במודע.

04 מדדים ו-KPIs — השפה של הדיווח



איור 6 · IoU: חפיפת תיבת החיזוי עם האמת

$$IoU(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad P = \frac{TP}{TP + FP} \quad R = \frac{TP}{TP + FN}$$

Precision — כמה מההתרעות אמיתיות · Recall — כמה מהעצמים נתפסו · סף ביטחון אחד מזיז את שניהם בכיוונים הפוכים

אין True Negative בגילוי: יש אינסוף תיבות ריקות אפשריות — TN לא מוגדר. כל המדדים בנויים מ-TP/FP/FN בלבד.

mAP — ומה שהוא מסתיר

$$AP = \frac{1}{101} \sum_{r \in \{0, 0.01, \dots, 1\}} \max_{\tilde{r} \geq r} p(\tilde{r}) \quad mAP_{@0.5:0.95} = \frac{1}{10} \sum_{t=0.50}^{0.95} AP_{IoU=t}$$


COCO: ממוצע דיוק על 101 נקודות recall, ואז ממוצע על 10 ספי IoU (עד 0.95 בקפיצות 0.05)

- $mAP@0.5 \neq mAP@0.5:0.95$ — נבדלים פי 1.35–1.45 טיפוסית. "mAP 0.91" בלי סף מוצהר $\approx$ תמיד המדד המקל. דגל אדום.
- "mAP" מחושב אחרת בכל benchmark (VOC ישן: 11 נקודות · VOC2010+: שטח מדויק · 101 COCO נקודות, ולא מבדיל AP מ-mAP). מספרים ממאמרים שונים אינם ברי-השוואה.

המדד המבצעי: התרעות שווא לשעה

$$FP/h = FP_{frame} \times FPS \times 3600 \Rightarrow 0.002 \times 25 \times 3600 = 180$$

180 התרעות שווא בשעה — מפעיל מפסיק להאמין למערכת. נמדד על וידאו רציף ריק מהיעד (TRAP-03)



איור 7 · precision ו-recall כפונקציה של סף הביטחון — בחירת נקודת עבודה היא החלטה מערכתית, לא אלגוריתמית

תרגום דרישה מבצעית ליעד נומרי — העבודה שלך

דרישה מבצעית	יעד מדיד
"לזהות רחפנים בזמן"	$\text{Recall} \geq 0.9$ עד טווח X בתנאי יום, על held-out ברמת סרטון
"לא להציף את המפעיל"	$2 \geq$ התרעות שווא לשעה על סצנה ריקה
"בזמן אמת"	$\text{Latency} \leq 200\text{ms}$ מחיישן להתרעה, על חומרת היעד
"מדויק"	$\text{mAP}@0.5:0.95$ מדווח עם הסף, אחרי ההמרה ל-edge

בלי מספרים חתומים — "המערכת עובדת" היא טענה שאי אפשר להפריך.


05 פרמטרים ו-Trade-offs — שיחה עם האלגוריתמיקאי

פרמטר	מה הוא עושה	מה מהנדס המערכת שואל
Learning Rate	גודל צעד; גבוה = קפיצות/NaN, נמוך = איטי	"יש warmup? מי כיוון ולמה?"
Batch Size	תמונות לצעד; גדול = יציב (BatchNorm)	"מוגבל ע"י זיכרון או החלטה?"
Epochs	סיבובים; יותר ≠ טוב (overfitting)	"איפה ה-early stopping ולמה שם?"
רזולוציית קלט	דיוק-קטנים ↑, אבל FLOPs ∝ רזולוציה ²	"מה זה עושה ל-latency על היעד?"
גודל מודל (x...n)	ציר דיוק → מהירות שלם במשפחה	"למה הגודל הזה מול חומרת היעד?"
Pretraining	התחלה ממשקלי COCO	"התחלנו ממשקלים מאומנים?" — המינוף הגדול ביותר: ויתור עלה עד 17 נק' AP (אבלציית Intel)
Early Stopping	עצירה כשה- val מפסיק להשתפר	"כמה GPU-שעות נחסכות?" — נמדד: פי 4–8.6
Augmentation	הגדלה מלאכותית של הדאטה	"מה Mosaic עושה לעצם הקטן ביותר?" (מכוון! מכבים ב-10 epochs אחרונים)
Optimizer	SGD/Adam — איך מתעדכנים משקלים	אינטואיציה בלבד; לא החלטת מנהל

$$\text{FLOPs} \propto \text{resolution}^2 \Rightarrow 640 \rightarrow 1280 = \times 4 \text{ compute}$$

הכפלת רזולוציה מרבעת את החישוב — "נגדיל את הקלט" הוא החלטת latency, לא free lunch

קריאת גרף אימון — ארבע צורות



איור 8 · Overfitting קלאסי: train יורד, val מתהפך ב-epoch 9 — נקודת ה-early stopping


- **בריא:** train ו- val יורדים יחד ומשתטחים.
- **Overfitting:** val מתהפך למעלה — עוצרים בתחתית.
- **LR גבוה מדי:** קפיצות/NaN — בשביל זה warmup.
- **Batch קטן מדי:** loss רועש.

ה-loss הוא proxy. אפשר לראות val loss משתפר בזמן שה-mAP תקוע. אל תאשרו על "יורד יפה".

← שאל: "מראים לי loss — מה ה-mAP וה-FP/שעה עשו באותו חלון?"

Tiling (SAHI): חיתוך הפריים לאריחים במקום כיווץ — AP +6.8% על עצמים קטנים בלי אימון מחדש, במחיר פי 4–9 בזמן inference. דיוק תמורת זמן, במספרים.

06 תהליך העבודה המלא — מדרישות לפריסה



איור 9 · Data Flywheel — הלולאה לא נסגרת אחרי ההשקה: פריסה ← איסוף כשלים ← תיוג ממוקד ← אימון ← פריסה

#	שלב	מה מהנדס המערכת מוודא
1	דרישות	מחלקות, טווחים, סנסור, חומרה, latency ו-FP/שעה — במספרים (טבלת פרק 4)
2	דאטה ותיוג	בעלים מוגדר; "תרחישי חובה" (לילה, ערפל, טווח); QA + guidelines עקביות
3	Baseline	מודל pretrained + כיול — baseline תוך ימים, לא חודשים
4	הערכה	טבלה אחת: mAP (עם סף!), P/R בנקודת העבודה, FP/שעה, latency על היעד
5	איטרציות	error analysis ← דאטה ממוקד ← סף ← מודל, בסדר הזה. 200 כשלים מנותחים < 10,000 תמונות אקראיות
6	פיילוט	מדידה "כמו בשטח": וידאו רציף, סצנות ריקות, תנאי היעד
7	פריסה וניטור	FP/שעה חי, drift (עונה, מזג אוויר, דגם חדש), champion/challenger, מחזור retraining


חלוקת הזמן האמיתית: ~80% מהעבודה היא דאטה (אנדרו נג — מספר-אצבע, לא מדידה; מחקר Google: "מפלי דאטה" ב-92% מהפייפליינים). גאנט שרובו "אימון וכיוון" בנוי הפוך — TRAP-17.

מ-detection ל-tracking — "יש זיהוי" זה חצי מערכת

גילוי עונה "יש רחפן בפריים"; מעקב עונה "זה **אותו** רחפן" — בלעדיו אין מסלול, מהירות או התרעה יציבה. הסטנדרט: tracking-by-detection עם מסנן קלמן (מצב SORT):

$$\mathbf{x} = [u, v, s, r, \dot{u}, \dot{v}, \dot{s}]^T \quad \hat{\mathbf{x}}_{k|k-1} = F \hat{\mathbf{x}}_{k-1} \quad \hat{\mathbf{x}}_k = \hat{\mathbf{x}}_{k|k-1} + K_k (z_k - H \hat{\mathbf{x}}_{k|k-1})$$

Predict: "איפה העצם אמור להיות לפי המהירות" (אי-הוודאות גדלה) · Update: מיזוג הניבוי עם המדידה במשקל Kalman gain — כך שורדים 2-1 פספוסים גילוי




איור 10 · שני מסלולים חוצים — נקודת החיתוך היא סיכון ID switch: "מתקרב" הופך ל"מתרחק"

$$t_{confirm} = N_{hits} \times \frac{1000}{FPS} = 3 \times 40ms = 120ms$$

אישור יעד אחרי N פריימים מדכא הבזקי-שווא — במחיר 120ms עיכוב התרעה. איזון FP ↔ latency מפורש

אל ה-Edge — תת-תהליך עם מלכודות משלו




איור 11 · שרשרת ההמרה ל-edge: האצה פי 2–5, אבל הדיוק נמדד מחדש על ה-engine הסופי

- **FP16**: כמעט חינם. **INT8**: נפילת 3%–7 mAP טיפוסית — ובכיוול גרוע, קריסה שקטה (מקרה מתועד: 0.05 – 0.36). העצמים הקטנים נופלים ראשונים — האות שלהם קרוב לרצפת רעש הקוונטיזציה.
- **חומרה (2026)**: Jetson Orin Nano ~67 TOPS / ~\$249 / YOLOv8n ~60FPS · Orin NX ~157 TOPS · AGX Orin ~275 TOPS ב-2.5W · Hailo-8: 26 TOPS

$$\sum_i t_i = t_{capture} + t_{pre} + t_{infer} + t_{NMS} + t_{track} + t_{alert} \leq \frac{1000}{FPS_{req}} ms$$

תקציב latency: שרשרת אמיתית שנמדדה (Orin Nano, YOLO11n INT8): $5.6+3.4+3.2 \approx 12ms$ — אבל capture והתרעה מוסיפים הרבה



איור 12 · כל חוליה נספרת מול תקציב ה-FPS — לא רק ה-inference

▲ TRAP-04 · "רץ ב-42FPS" מדבר על מהירות בלבד

FPS ודיוק הם שני מספרים נפרדים; שניהם נמדדים על אותו engine, על היעד.

← שאל: "מדדתם mAP אחרי ההמרה ל-INT8, על חומרת היעד — או רק FPS?"

מונח	הסבר במשפט
Focal Loss	פיצוי על חוסר איזון רקע/עצמים קיצוני
Epoch	מעבר מלא על דאטת האימון
Overfitting	שינון; val loss מתהפך למעלה
Frame Leakage	פריימים מאותו סרטון בשני הצדדים ← mAP שקרי
Domain Gap	דאטה לא מתנאי היעד ← צניחה בשטח
Tiling / SAHI	חיתוך במקום כיווץ; פי 4–9 בזמן
Tracking	שיוך בין פריימים ← זהות, מסלול, מהירות
ID Switch	החלפת זהויות בין עצמים בחצייה
Kalman Filter	ניבוי לפי מהירות + עדכון לפי מדידה
ONNX / TensorRT	מהמודל המאומן ל-engine על היעד
Quantization	FP16 כמעט חינם; INT8 דורש כיול
Latency	מהפריים להחלטה, על חומרת היעד בלבד
Data Flywheel	פריסה ← כשלים ← תיוג ← אימון ← פריסה
Drift	העולם משתנה והמודל נשחק בשקט

מונח	הסבר במשפט
Object Detection	קלט: פריים; פלט: עצמים עם מחלקה ותיבה
Bounding Box	ארבעה מספרים שתוחמים עצם
Classification	תווית אחת לתמונה — בלי "איפה"
Segmentation	מסכה פיקסל-לפיקסל; מדויק ויקר מתיבה
IoU	חיתוך ÷ איחוד, 0–1; סף 0.5 = "פגיעה"
Precision	כמה מההתרעות היו אמיתיות
Recall	כמה מהעצמים שהיו — נתפסו
mAP	שטח תחת עקומת P-R; חסר משמעות בלי סף IoU
FP/Hour	המדד שהמפעיל מרגיש; על וידאו רציף ריק
NMS	מוחק תיבות כפולות על אותו עצם
Anchor	תבניות תיבה; הדור החדש anchor-free
Backbone	חילוך מאפיינים — קונבולוציות מוערמות
FPN / Neck	מיזוג סקאלות לקטנים וגדולים יחד
One/Two-Stage	מהיר-ישיר מול דו-שלבי מדויק-היסטורית

נספח · צ'קליסט לפני כל Demo Review

□ החלוקה train/test ברמת סרטון — אומתה

□ המדד כולל סף IoU מוצהר

□ הדמו רץ על held-out שהצוות לא ראה

□ FP/שעה נמדד על וידאו רציף ריק

□ mAP נמדד אחרי quantization, על חומרת היעד

□ קיים מסמך annotation guidelines

□ error analysis בוצע לפני בקשת "עוד דאטה"

מקורות עיקריים: · Ultraalytics docs · Zalesskaya et al. arXiv:2211.17170 · Wu, Sahoo, Hoi arXiv:1908.03673 · Ilioudi et al. TU Delft 22-004 · Horak, mAP lecture (BUT) · SAHI arXiv:2202.06934 · RT-DETR arXiv:2304.08069 · Anti-UAV arXiv:2504.11967 · ByteTrack/BoT-SORT · TensorRT GH #1114 · Sambasivan et al., CHI 2021
 נלווה: אפליקציית תרגול אינטראקטיבית drone-academy.html — מסלול, מעבדות חיות ומבחני החלטה על אותו חומר.